PENGEMBANGAN SISTEM REKOMENDASI ADAPTIF REAL-TIME UNTUK DESTINASI WISATA: OPTIMALISASI KEBERAGAMAN DAN CAKUPAN GUNA MENDORONG PEMERATAAN DISTRIBUSI PARIWISATA

M Egypt Pratama - 23523311

Dosen Pembimbing:
Dr. Ir. Arry Akhmad Arman, M.T.

Dosen Penguji:
Dr. techn. Ir. SaifulAkbar, S.T., M.T.
Dessi Puji Lestari, S.T., M.Eng., Ph.D.

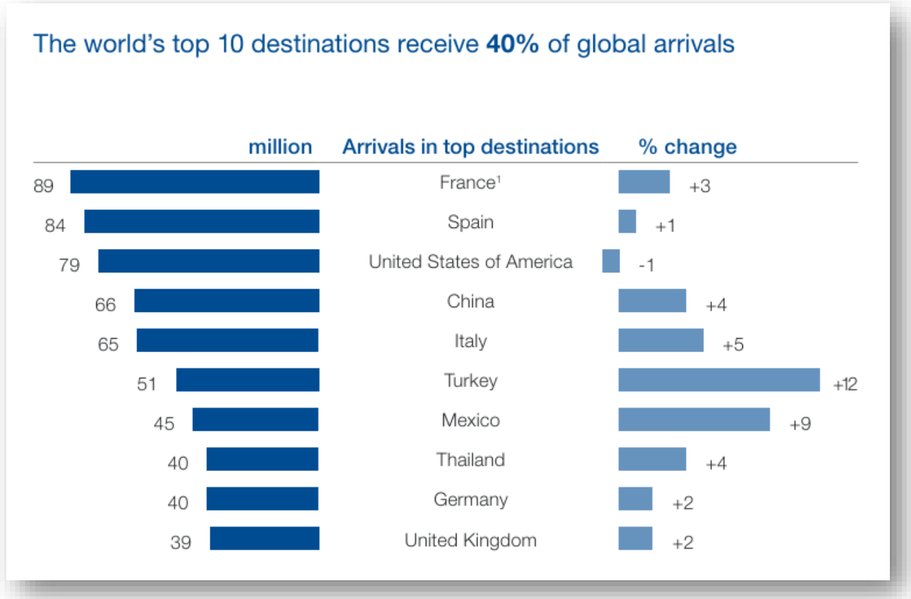
Outline Presentasi

1. Pendahuluan
2. Metodologi Penelitian
3. Desain Solusi
4. Implementasi dan Hasil
5. Kesimpulan dan Saran

1. Pendahuluan

Latar Belakang

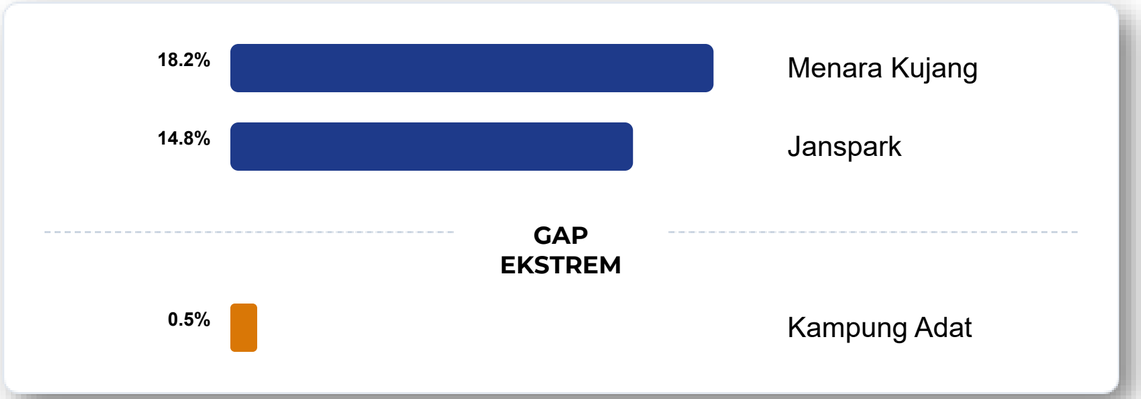
- **Fenomena Global (UNWTO):** 10 destinasi teratas menyerap 40% total wisatawan dunia.



Dampak Ganda:

Overtourism	Gurun Ekonomi
Kerusakan infrastruktur	UKM lokal bangkrut
Hilang autentisitas	Potensi terabaikan

DATA EMPIRIS SUMEDANG (77 DESTINASI)



72.4% kunjungan hanya ke Top 10 destinasi.

TRANSFORMASI DIGITAL PARIWISATA

Information Overload Problem:
Ledakan informasi digital menyebabkan kesulitan pengambilan keputusan bagi wisatawan.

Latar Belakang

Masalah Utama

Teknologi seharusnya mendemokratisasi akses, namun sistem rekomendasi konvensional justru memperburuk ketimpangan melalui **Bias Popularitas**.



Penelitian	Metode	Hasil/Kontribusi	Keterbatasan
Fararni dkk. (2021)	Hybrid RS (CF+CB+Context)	Integrasi konteks (waktu, lokasi) meningkatkan relevansi.	Konteks statis (bukan real-time); Pre-filtering memperburuk data sparsity.
Yalcin & Bilge (2021)	MMR Statis (VaR, AdaptedVaR)	Efektif kurangi bias popularitas dengan akurasi terjaga.	Parameter λ statis; tidak adaptif terhadap perubahan konteks dinamis.
Abdollahpouri dkk (2021)	Calibrated Popularity (CP)	Distribusi lebih adil melalui bobot terbalik popularitas.	Terbatas pada bias model
Yoon & Choi (2023)	Context-Aware AI (Suhu, Hujan)	Merefleksikan faktor eksternal lingkungan.	Tidak adaptif real-time; gagal menangani concept drift & perubahan preferensi.
Shi dkk. (2023)	Multi-objective (MAB + MMR)	Pembelajaran adaptif dari feedback pengguna.	Belum fokus pada pemerataan pariwisata (long-tail); perlu data unbiased.

Sistem Rekomendasi Pariwisata Adaptif Berbasis MAB-MMR

- Optimalisasi Parameter Dinamis: Pengembangan sistem difokuskan pada integrasi Multi-Armed Bandit (MAB) dengan Maximal Marginal Relevance (MMR) untuk menyesuaikan parameter keseimbangan λ secara dinamis berdasarkan kondisi terkini pengguna.
- Adaptivitas Otomatis: Mekanisme ini dirancang untuk menyeimbangkan relevansi dan keberagaman tanpa penalaan parameter manual, sehingga mampu mengatasi kekakuan sistem statis dalam menghadapi perubahan preferensi.
- Integrasi Konteks Multimodal: Arsitektur sistem mengonsumsi aliran data cuaca, kalender, mobilitas, dan tren media sosial untuk menghasilkan rekomendasi yang peka terhadap situasi lingkungan secara real-time.
- Mitigasi Bias Popularitas: Metode ini bertujuan memitigasi dominasi destinasi populer yang sering diperkuat oleh algoritma konvensional, guna mendorong distribusi kunjungan yang lebih merata.
- Promosi Destinasi Long-Tail: Rancangan fungsi imbalan (reward) mengombinasikan aspek akurasi dan kebaruan untuk memperluas eksposur destinasi berkualitas yang selama ini terabaikan dalam katalog.

Rumusan Masalah

1. Bagaimana optimasi dinamis parameter λ pada MMR menggunakan **Multi-Armed Bandit** dapat meningkatkan keberagaman tanpa mengorbankan akurasi?
2. Seberapa besar pengaruh integrasi **data kontekstual** (cuaca, waktu) dalam mendorong pemerataan distribusi kunjungan
3. Sejauh mana sistem adaptif dapat meningkatkan eksposur **destinasi kurang populer** (long-tail) dan kepuasan pengguna

Tujuan

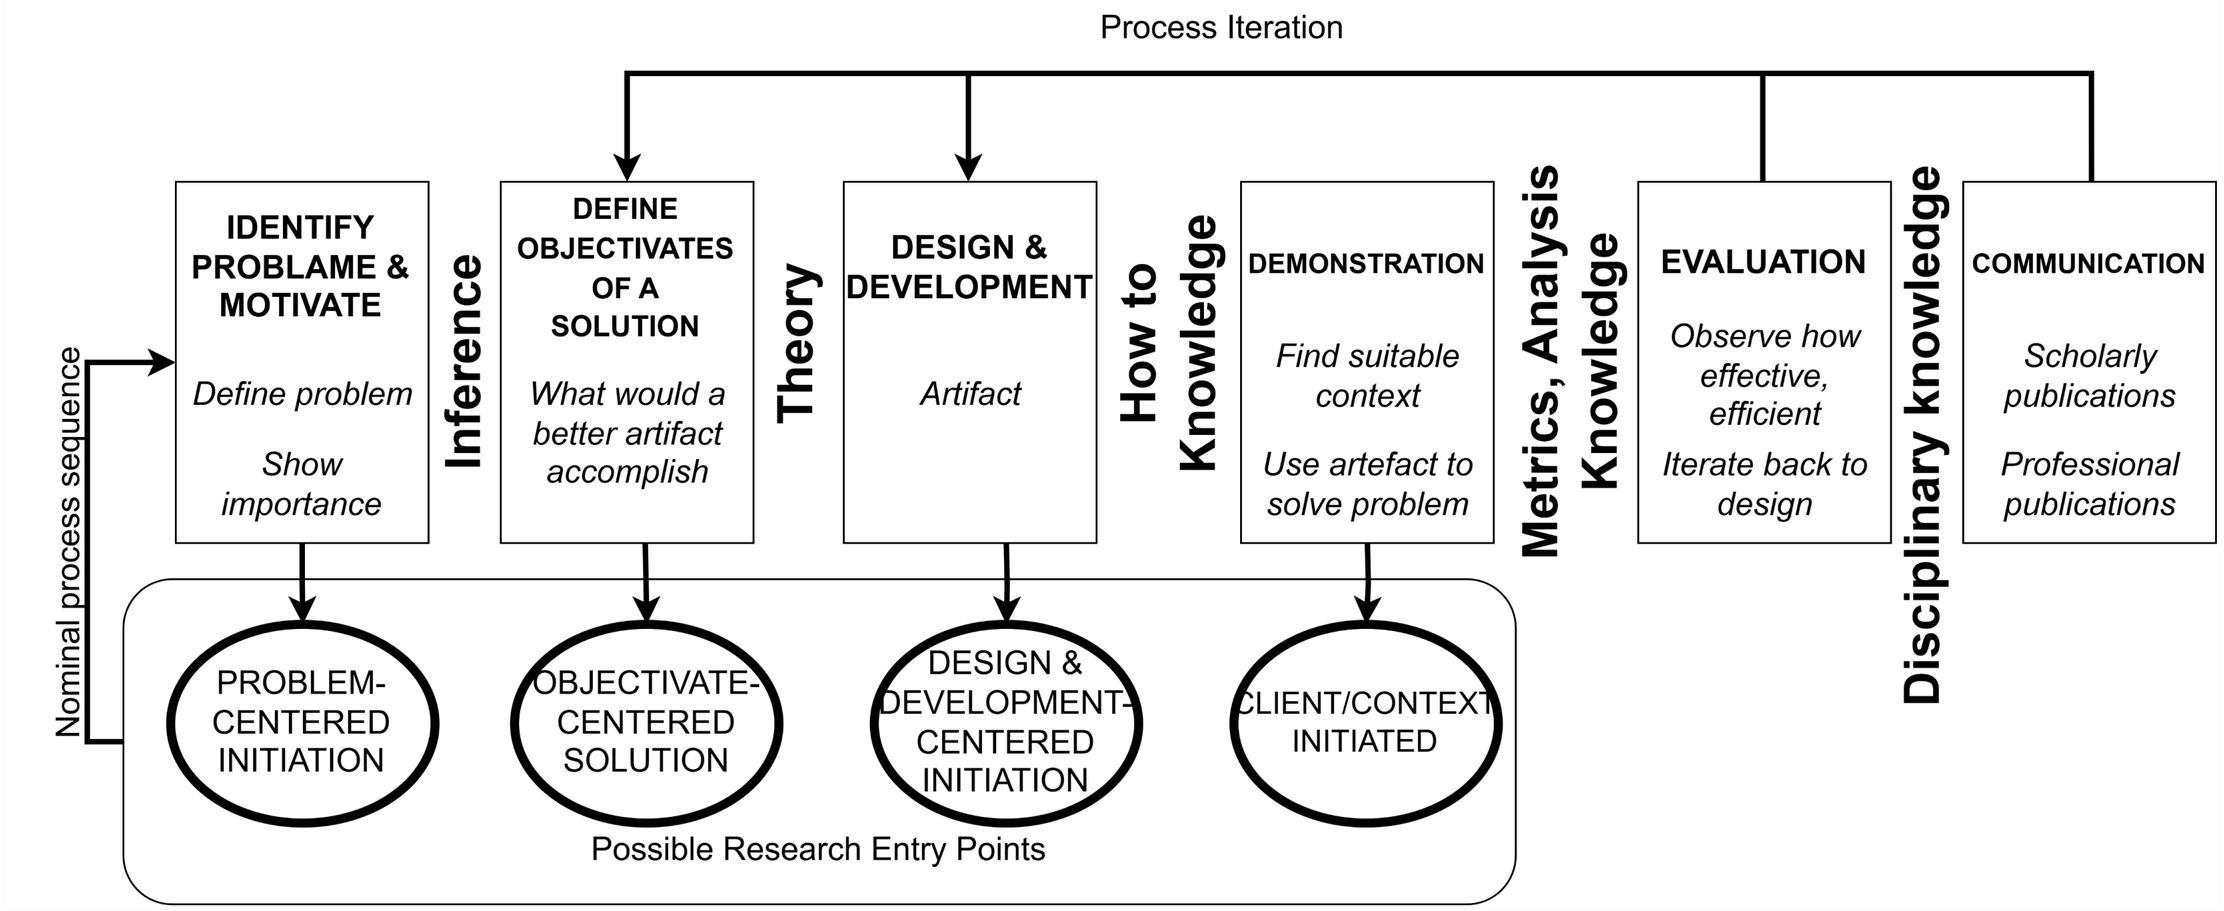
Mengembangkan sistem adaptif (MAB-MMR) untuk memitigasi *Popularity Bias* dan mendorong pemerataan distribusi wisata.

Batasan Masalah

1. Lokasi penelitian: Kabupaten Sumedang
2. Penggunaan data kontekstual dinamis meliputi cuaca dan kalender secara real-time melalui API, serta model simulasi untuk kondisi lalu lintas dan tren media sosial guna validasi logika adaptasi algoritm
3. Evaluasi performa sistem mencakup metrik Precision@K, NDCG, Gini Coefficient, Intra-List Diversity, Coverage@K, dan Novelty

2. Metodologi Penelitian

Metodologi DSRM



3. Desain Solusi

Kebutuhan Fungsional dan Non Fungsional

Kebutuhan Fungsional

- Sistem harus dapat mengintegrasikan data kontekstual (minimal dua dari: cuaca, lalu lintas, atau tren media sosial)
- Sistem harus menghasilkan rekomendasi menggunakan model Hybrid dengan mekanisme MAB-MMR
- Sistem harus dapat menerima input preferensi pengguna dan menghasilkan rekomendasi yang dipersonalisasi
- Sistem harus menyediakan antarmuka web untuk menampilkan rekomendasi destinasi beserta justifikasinya
- Sistem harus dapat menerima feedback pengguna (rating atau interaksi) untuk evaluasi

Kebutuhan Non Fungsional

- Response Time:
  - ❑ Offline evaluation: Response time tidak lebih dari 500ms (tanpa latency API eksternal karena menggunakan cached data)
  - ❑ User testing: Response time tidak lebih dari 3 detik untuk 90% request
- Sistem harus dapat mengoptimumkan metrik akurasi (Precision@K, NDCG) dan keberagaman (Diversity, Coverage) secara seimbang
- Sistem harus dapat diakses melalui web browser dan memiliki target System Usability Scale (SUS) score minimal 70
- Sistem harus memiliki mekanisme penanganan eror yang memadai untuk menjaga stabilitas selama pengujian
- Sistem harus memiliki mekanisme fallback untuk mengatasi kegagalan API eksternal, menggunakan data cache dengan timestamp maksimal 30 menit

Analisis Solusi

Solusi	Keunggulan	Keterbatasan
MMR Statis	Sederhana, komputasi ringan	Tidak adaptif, manual tuning, trade-off kaku
RL-MDP	Pembelajaran sekuensial optimal	Data-hungry, lambat, overhead tinggi
MAB-MMR ✅	Ringan, real-time, auto-tuning	(dipilih karena balance optimal)

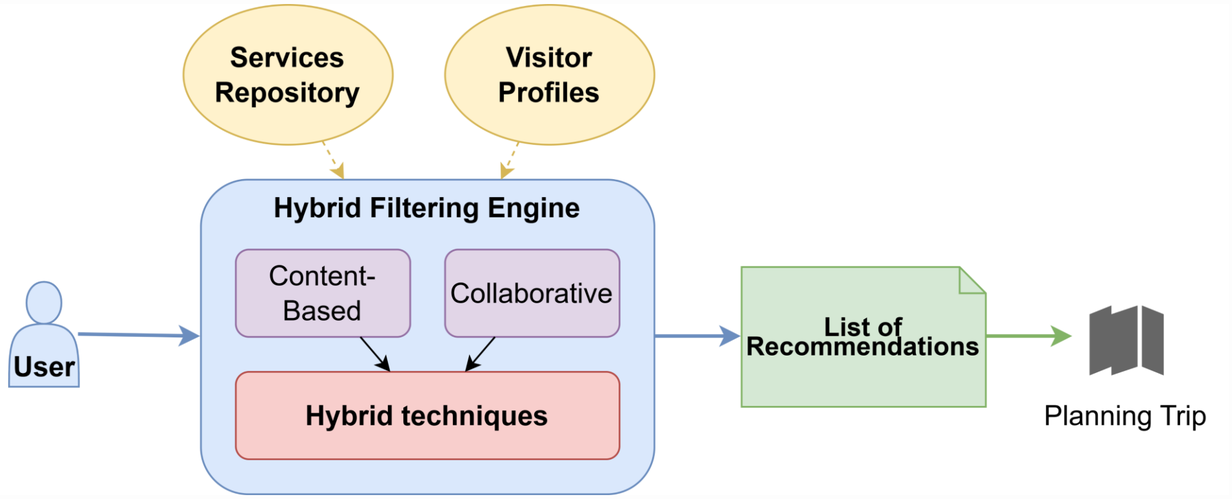
Solusi Terpilih:

Hybrid (CF+CB+Context) + MMR + MAB

Justifikasi:

- **Hybrid** → Atasi cold-start & coverage
- **MMR** → Diversifikasi ringan
- **MAB** → Optimasi λ dinamis real-time

Rancangan Solusi



Sistem Existing: Baseline (Fararni dkk., 2021)

Karakteristik:

- **Arsitektur:** Feed-forward satu arah
- **Input:** Profil pengguna statis + Repositori wisata
- **Engine:** Hybrid Filtering (CF + CB) dengan pembobotan kaku

Sistem Usulan

Karakteristik:

- **Arsitektur:** Closed-loop dengan feedback adaptif
- **Input:** Profil pengguna + Repositori wisata + **Context real-time**+ Feedback user
- **Engine:** Adaptive Hybrid (CF+CB+Context) + MMR + MAB
- **Output:** Rekomendasi adaptif context-aware

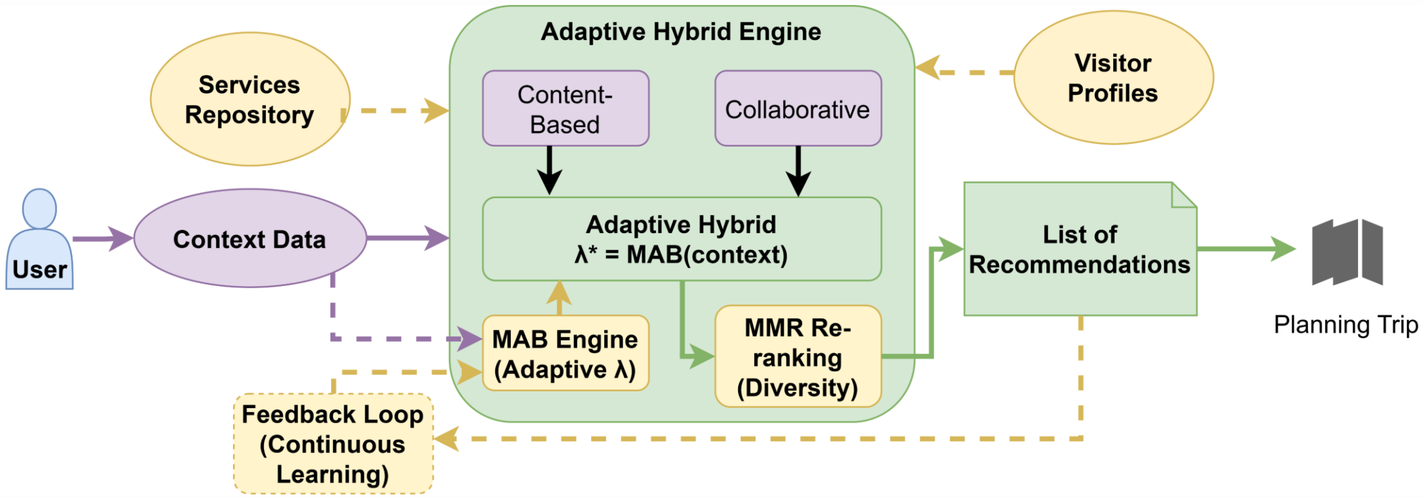
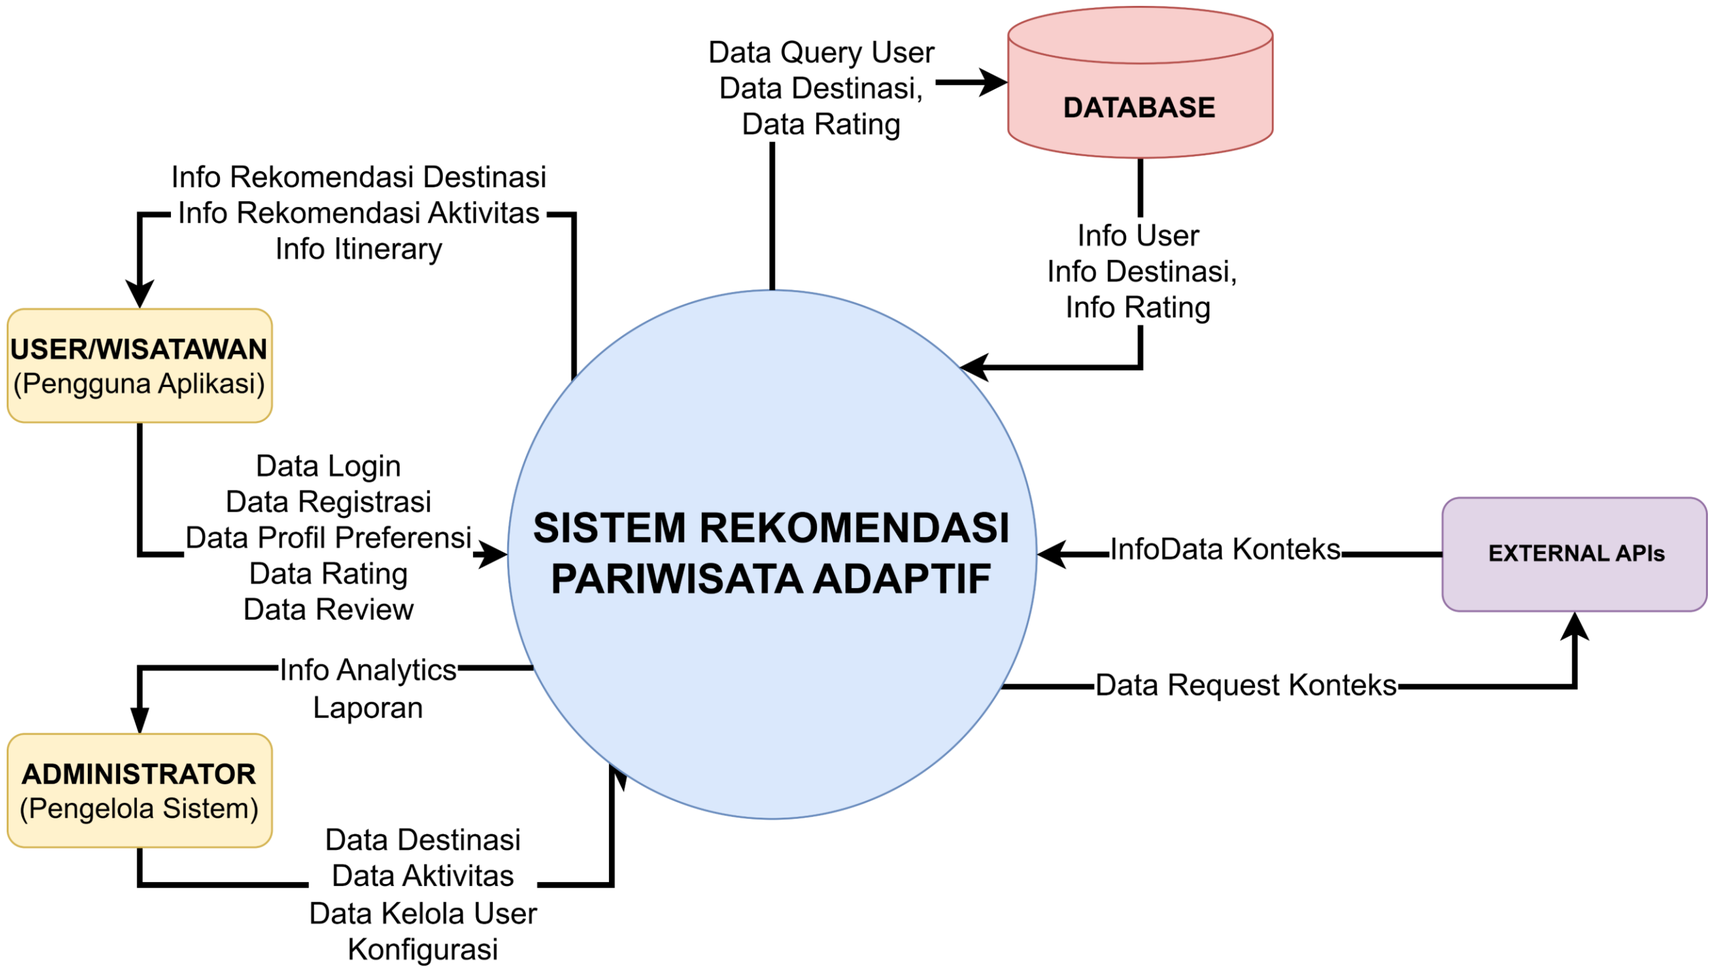
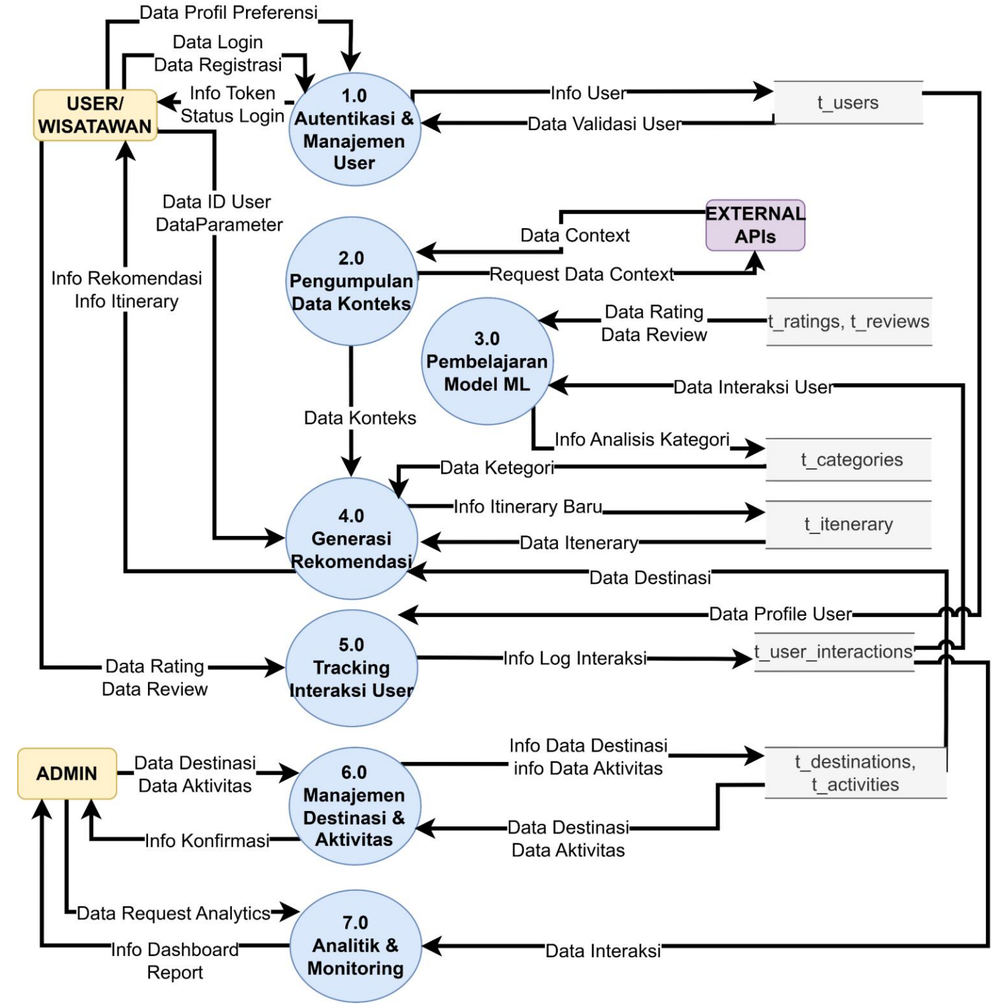


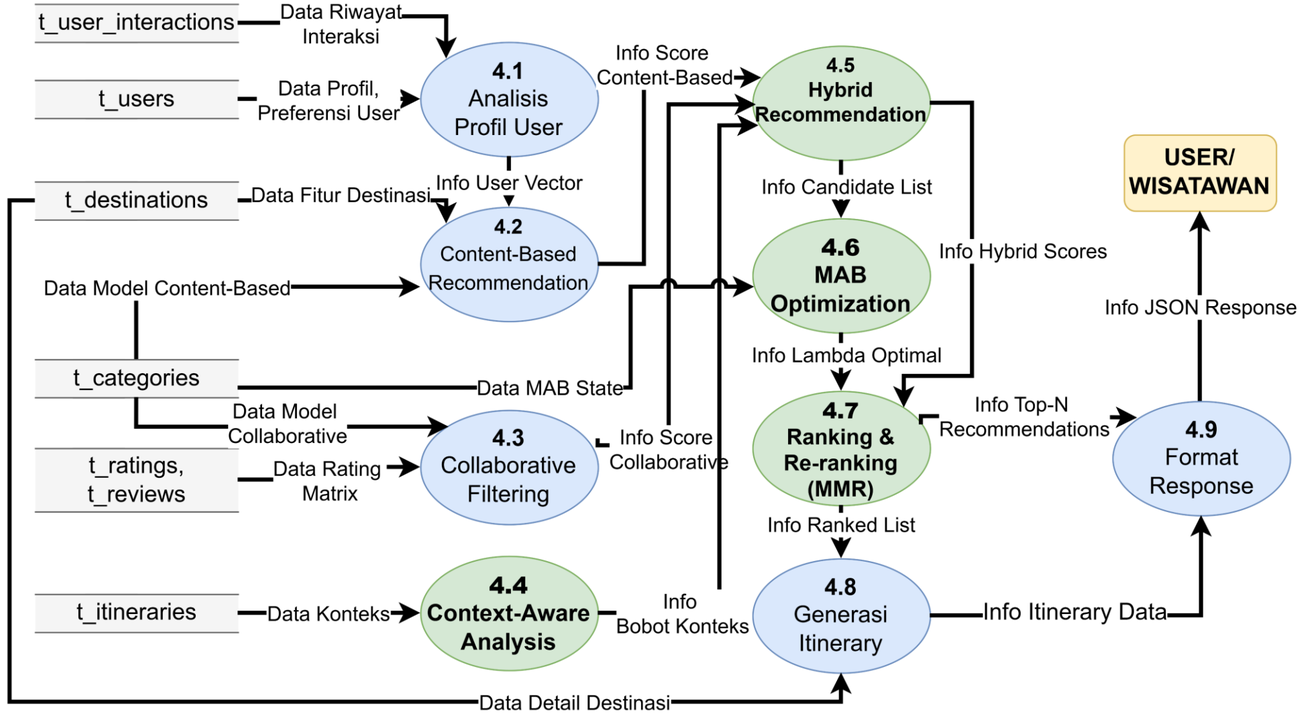
Diagram Konteks



DFD Level 0



DFD Level 1 Proses 4



Metode Evaluasi

OFFLINE (QUANTITATIVE)

Metrics:

- **Akurasi:** NDCG@10 (Ranking Quality).
- **Diversity:** Intra-List Diversity.
- **Fairness:** Gini Coefficient.

Validation: Paired t-test (sig 0.05).

ONLINE (QUALITATIVE)

System Usability Scale (SUS): Standardized.

Target > 70 (Good).

Protokol Pengujian

Kategori 1: Baseline Fundamental (tanpa diversifikasi)

1. Popularity-Based
2. Collaborative Filtering (NMF)
3. Content-Based (TF-IDF)
4. Hybrid (CF + CB, tanpa konteks)

Kategori 2: Static Diversification (dengan konteks)

1. Hybrid + MMR-λ0.0 (murni relevansi)
2. Hybrid + MMR-λ0.3 (orientasi relevansi)
3. Hybrid + MMR-λ0.5 (seimbang - baseline utama)
4. Hybrid + MMR-λ0.7 (orientasi keberagaman)
5. Hybrid + MMR-λ1.0 (murni keberagaman)

Kategori 3: Model Usulan

Hybrid + MAB-MMR (seleksi λ adaptif)

Eksperimen & Karakteristik Data

224
DESTINASI
Data Riil Sumedang (12 Tahun)

0.6%
SPARSITY
Sangat Ekstrem (Matrix Kosong)

99.7%
COLD-START
User dengan < 10 ratings

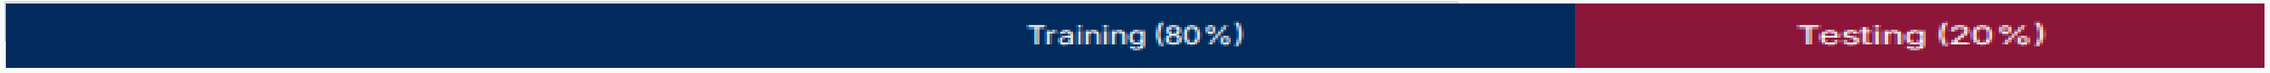
Tantangan Utama

Mayoritas user adalah pengguna baru.

Strategi Mitigasi

Hybrid Architecture: Fallback otomatis ke Content-Based + Context Boosting.

Data Split Strategy



4. Implementasi dan Hasil

Implementasi Sistem

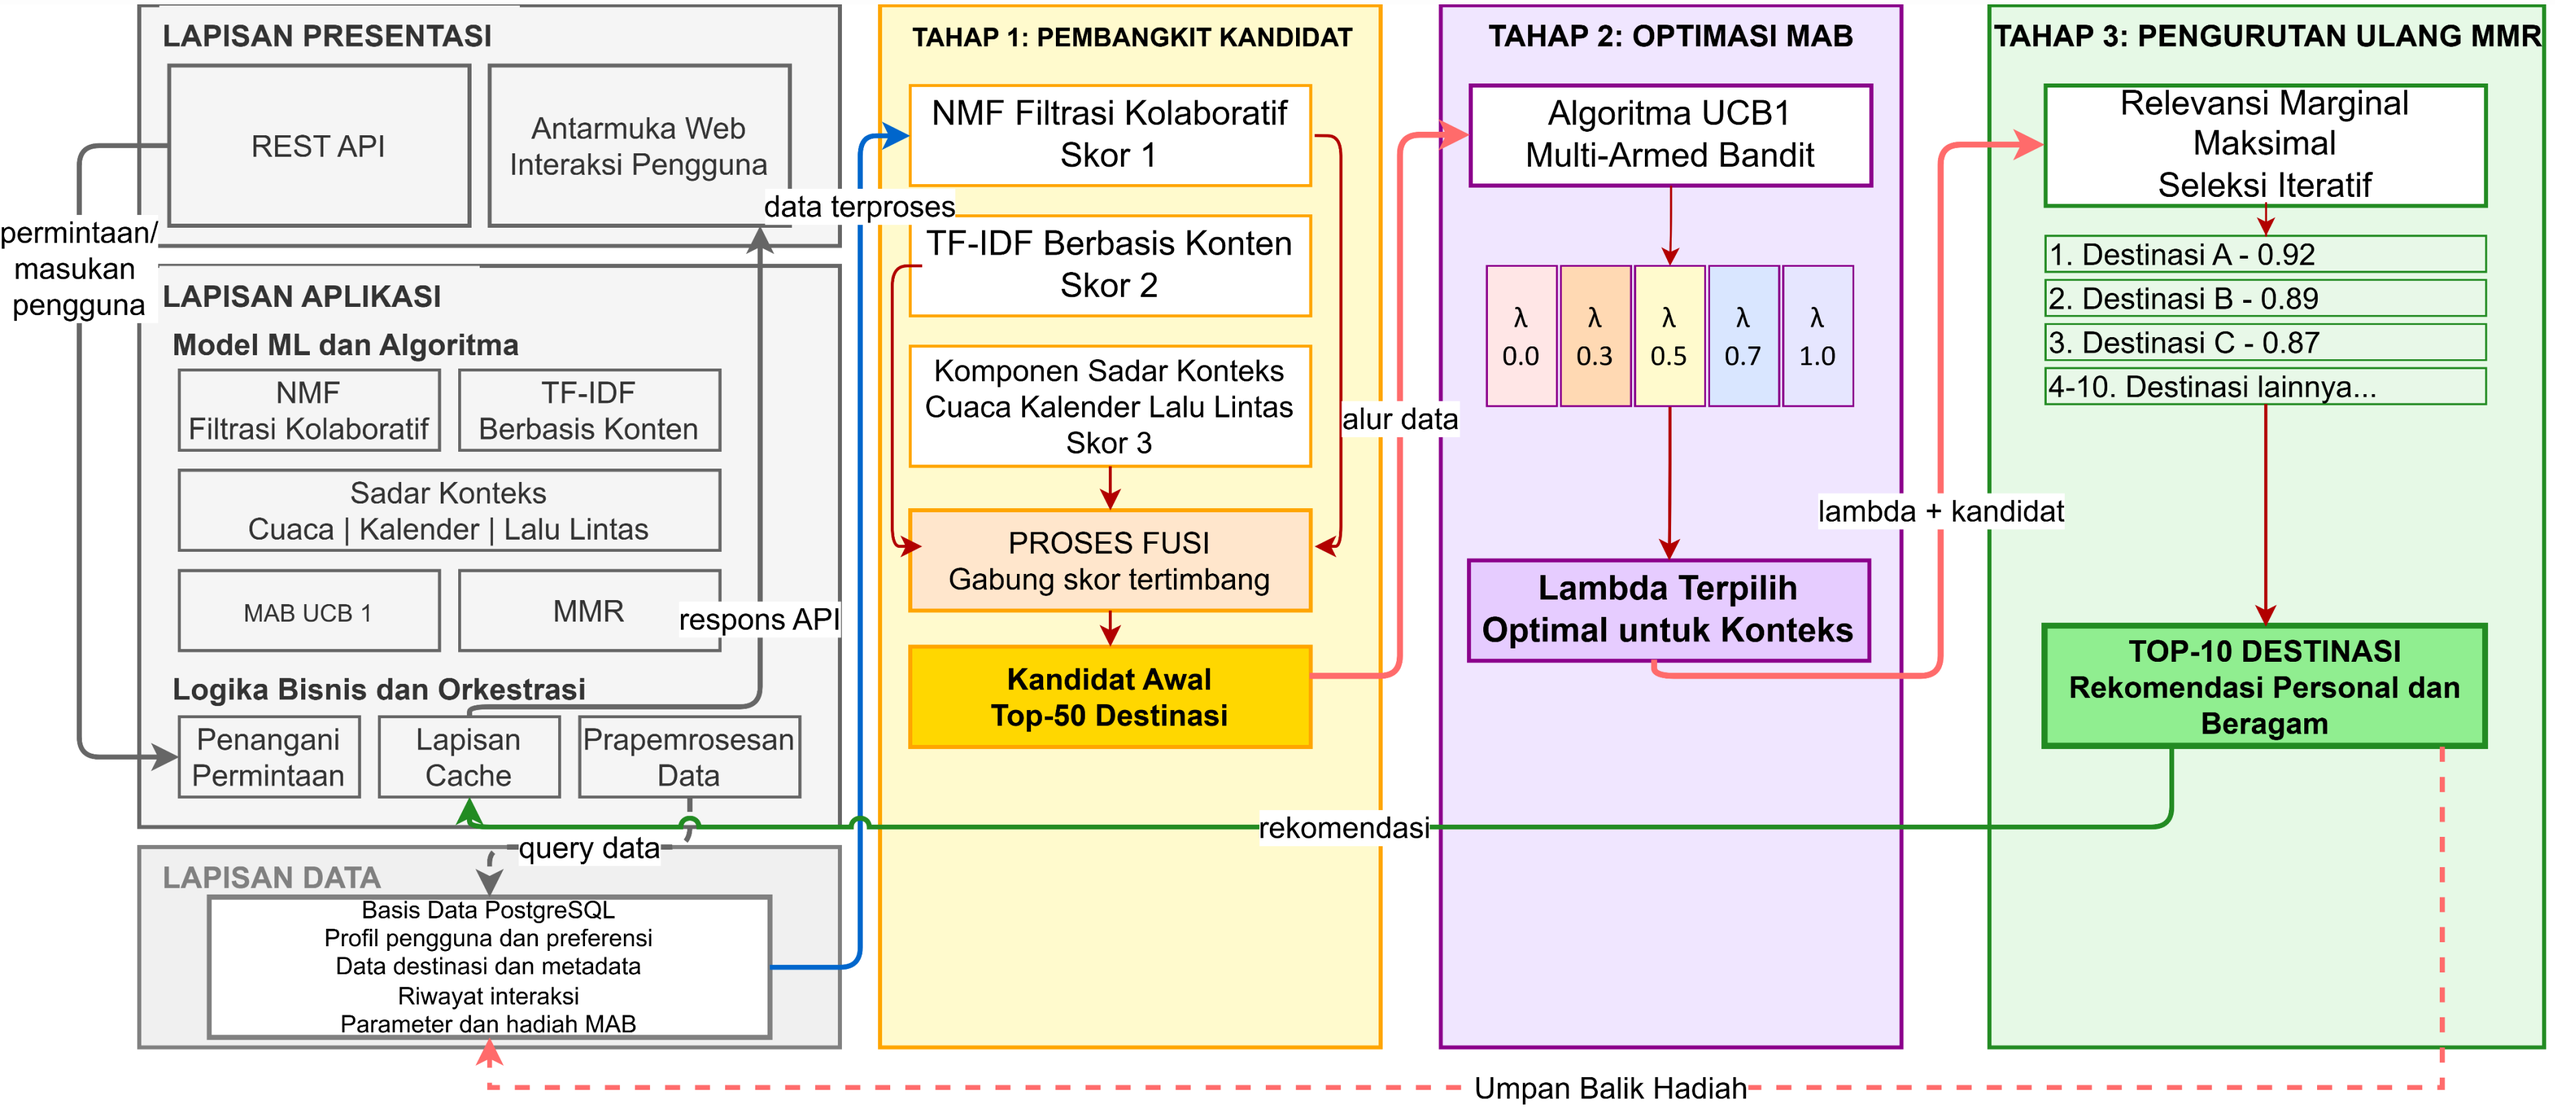
Technology Stack

- Language: Python 3.9
- RS Library: Surprise
- ML Library: scikit-learn
- NLP: TfidfVectorizer
- Data: Pandas, NumPy
- API: FastAPI

Spesifikasi Sistem

- Processor Intel Core i5-1335U
- RAM 16GB DDR5
- Storage 512GB NVMe SSD
- Konfigurasi eksperimen menggunakan random seed global 42 untuk reprodusibilitas, seperti yang didefinisikan dalam notebook evaluasi

Arsitektur Sistem



Layer 1: Candidate Generation

Hybrid Context-Aware Approach

Fungsi Utama: Menghasilkan kandidat destinasi awal dengan menggabungkan tiga komponen skor sebelum masuk tahap optimasi.

1. Collaborative (CF)

ALGORITHM: NMF

Menggunakan **Non-negative Matrix Factorization** dengan parameter n_factors=20.

Tujuan: Menangkap pola preferensi laten dan kolaboratif antar pengguna.

2. Content-Based (CB)

ALGORITHM: TF-IDF

Menggunakan **TF-IDF** pada metadata kategori destinasi.

Tujuan: Stabilitas untuk menangani skenario **cold-start ekstrem**.

3. Context-Aware

LOGIC: ADDITIVE

Menerapkan logika **Boost (+)** atau **Penalty (-)** langsung pada skor.

Contoh: Cuaca hujan = penalty outdoor, boost indoor.

$$Score(u,i,c) = \alpha CF(c) \cdot ScoreCF + \alpha CB(c) \cdot ScoreCB + \alpha Ctx(c) \cdot ScoreContext$$

Layer 2: Optimasi Adaptif (MAB)

Multi-Armed Bandit Parameter Selection

Mekanisme Inti (UCB1)

Menggunakan algoritma **Upper Confidence Bound (UCB1)** untuk memilih parameter λ secara dinamis.

- **Exploration:** Mencoba strategi λ yang jarang dipakai.
- **Exploitation:** Memilih strategi λ dengan reward rata-rata terbaik.
- **Tujuan:** Menyesuaikan trade-off akurasi-diversitas berdasarkan konteks pengguna saat itu.

Fungsi Reward Komposit

MAB belajar memaksimalkan fungsi tujuan gabungan:



Konfigurasi Arms (λ)

5 nilai diskrit yang merepresentasikan spektrum strategi:

0.0 Relevance	0.3 Mix-Rel	0.5 Balanced	0.7 Mix-Div	1.0 Diversity

$$UCB = \mu + c \cdot \sqrt{(\ln t / N)}$$

Layer 3: Re-ranking & Diversifikasi

Maximal Marginal Relevance (MMR) Implementation

Fungsi Utama

Menyusun ulang daftar kandidat menjadi rekomendasi final **(Top-N)** menggunakan parameter λ yang telah dipilih oleh MAB pada layer sebelumnya.

Algoritma MMR

Melakukan seleksi iteratif (Greedy) untuk menyeimbangkan:

- **Relevansi Item:** Seberapa cocok item dengan user.
- **Dissimilarity:** Seberapa beda item dengan yang sudah terpilih di list.

$$FinalScore_i = \lambda \cdot Rel_i - (1 - \lambda) \cdot \max Sim(i,j) + \gamma \cdot Bonus_i$$

Komponen Persamaan

1. Relevansi (Rel)
Skor prediksi awal dari Layer 1.

2. Diversitas (Penalty)
Hukuman jika item terlalu mirip dengan set terpilih $Sim(i,j)$.

3. Koreksi Bias (γ)
Memberikan "bonus" skor untuk destinasi berkualitas namun kurang populer (Hidden Gems) guna memitigasi Popularity Bias.

Hasil Kuantitatif

Perbandingan Model Performance

Model	NDCG@10	Diversity (ILD)	LT-Coverage (%)	Gini Index
Hybrid (Baseline)	0.0244	0.5801	67.86	0.6414
Hybrid + MMR (λ = 0.5)	0.0201	0.7468	71.43	0.6608
Hybrid + MAB-MMR	0.0237	0.6003	69.64	0.6401

Key Findings

Diversity Improvement

+3.5%

vs Baseline

Dampak Riil

+52.8% Exposure

untuk Destinasi Long-Tail

Long-Tail Coverage Tertinggi

69,64%

Hasil Kualitatif

Evaluasi Pengguna (n=30)

Overall SUS Score

79.1 / 100

Grade: B+ (Good)

Discovery Rate

96.7%

Menemukan destinasi baru menarik

Satisfaction: Relevance

4.2 / 5.0

Rekomendasi sesuai preferensi

Satisfaction: Diversity

4.5 / 5.0

Variasi rekomendasi

Qualitative Feedback

Positive Feedback

- Menemukan destinasi yang tidak pernah tahu sebelumnya“
- Rekomendasi tidak monoton, ada variasi menarik“
- Sesuai dengan waktu kunjungan saya“
- Membantu eksplorasi destinasi baru"

Areas for Improvement

- "Perlu info jarak dan aksesibilitas lebih detail“
- Ingin filter berdasarkan kategori spesifik"

Interpretasi

SUS Score 79.1 berada di kategori **"Good to Excellent"** (percentile 85th). Discovery Rate 96.7% menunjukkan sistem berhasil **mendorong eksplorasi** destinasi long-tail. User satisfaction tinggi pada diversity (4.5/5) mengkonfirmasi **keberagaman tidak mengorbankan relevansi** (4.2/5).

Intrepensi Temuan Utama

FINDING 1

Adaptive λ Works

MAB otomatis menghindari over-diversifikasi pada data sparse, menjaga relevansi.

FINDING 3

High Acceptance

SUS 79.1 membuktikan sistem kompleks ini tetap intuitif.

FINDING 2

No Accuracy Penalty

Diversity naik 3.5% TANPA penurunan akurasi signifikan.

FINDING 4

Context Boosts Long-Tail

Fitur cuaca/waktu efektif mengangkat item spesifik (contoh: Indoor saat hujan).

Implikasi Praktis & Keterbatasan Penelitian

Implikasi Praktis

Dinas Pariwisata: Instrumen teknis untuk mitigasi *overtourism* berbasis data.

Ekonomi Lokal: Destinasi berkualitas (Rating >4.5) mendapatkan kenaikan eksposur hingga **+52%** tanpa biaya iklan.

Efisiensi Sistem: Algoritma ringan dengan latensi **197ms**, siap untuk implementasi produksi.

Keterbatasan Penelitian

Cakupan Geografis: Terbatas pada Sumedang (Dominasi wisata alam/pegunungan).

Data Konteks: Data Lalu Lintas & Tren Sosmed menggunakan **simulasi logika** (karena batasan biaya akses API Enterprise).

Profil Responden: User testing (n=30) didominasi oleh demografi **Mahasiswa/Wisatawan Muda**, mungkin memiliki bias preferensi digital.

Komunikasi Hasil Penelitian

Buku Tesis

Pengembangan Sistem Rekomendasi Adaptif Real-time untuk Destinasi Wisata: Optimalisasi Keberagaman dan Cakupan guna Mendorong Pemerataan Distribusi Pariwisata

Paper

A Hybrid-Adaptive Recommender System for Fair Promotion of Cultural Heritage Tourism: Mitigating Popularity Bias

5. Kesimpulan dan Saran

Kesimpulan & Saran

Kesimpulan

1. Algoritma Multi-Armed Bandit (MAB) berhasil memecahkan masalah bias popularitas, meningkatkan keberagaman +3,5% dengan akurasi stabil (NDCG=0,0237), mengungguli parameter statis +17,9%.
2. Integrasi kontekstual meningkatkan Diversity +7,21% dan NDCG +1,24%, mencapai Long-Tail Coverage tertinggi 69,64% (Gini 0,6401), membuktikan pergeseran dari destinasi populer ke alternatif.
3. Peningkatan eksposur hidden gems signifikan (Curug Pasirwangi +52,78%). Validasi pengguna (n=30): discovery rate 96,7%, SUS 79,1, perceived diversity 4,3/5,0 pemerataan tercapai tanpa mengurangi kepuasan.

Saran

1. Validasi generalisabilitas pada destinasi berbeda (wisata perkotaan) untuk menguji ketahanan strategi adaptif.
2. Ekspansi user testing (n ≥ 50 per grup) untuk meningkatkan statistical power dan analisis subgroup.
3. Eksplorasi automated reward function tuning (hyperparameter optimization, multi-objective evolutionary algorithms).
4. Integrasi deep learning (Neural CF, VAE, GNN) dengan perhatian pada trade-off kompleksitas dan interpretability.

Terima Kasih

Atas Perhatian

BACKUP SLIDE

Validasi Statistik

Paired t-Test Analysis & Parameter Learning Patterns (N=1,714 users)

1. vs Hybrid Baseline

NDCG@10 (Accuracy) Trivial (d=-0.03)

Diff: **-0.0007 (-2.9%)** p-value: **0.1998 (ns)**

H3 Confirmed: No significant degradation.

Diversity Score Medium (d=0.33)

Diff: **+0.0201 (+3.5%)** p-value: **< 0.001 (Sangat Signifikan Sekali)**

H2 Confirmed: Significant improvement.

Keberagaman meningkat tanpa penurunan akurasi.

2. vs Static MMR (λ=0.5)

NDCG@10 Small (d=0.07)

Diff: **+0.0036 (+17.9%%)** p-value: **0.0070 (Sangat Signifikan)**

Dynamic selection outperforms static balanced strategy.

Diversity Score

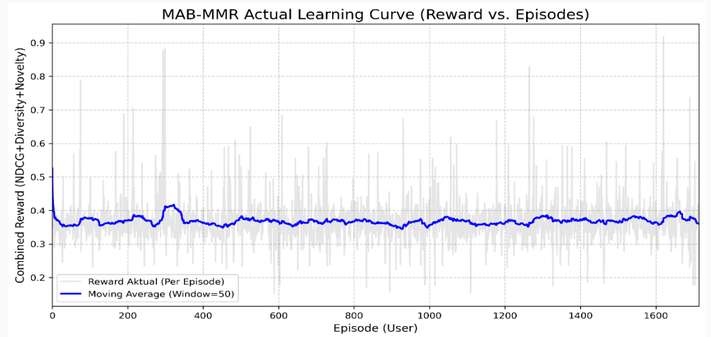
Diff: **-0.1466 (-19.6%)** p-value: **< 0.001 (Sangat Signifikan Sekali)**

Deliberate trade-off: System prioritizes relevance.

Asumsi keseimbangan statis terbukti suboptimal pada kondisi data yang jarang (sparse)

3. Learning Pattern (λ)





Convergence Timeline:

Early (1-200) Exploration Phase

Mid (200-600) Convergence to λ≤0.3

Late (600+) **97% Low Lambda**

Strategi berbasis data: Mengalokasikan fokus pembelajaran pada relevansi

Comparison	Metric	Result	Significance	Effect Size
vs Hybrid	Accuracy (NDCG)	-0.0007 (ns)	Not Significant	Trivial
vs Hybrid	Diversity	+0.0201 (sig)	p < 0.001	Medium (Notable)
vs Static 0.5	Accuracy (NDCG)	+0.0036 (sig)	p = 0.007	Small
vs Static 0.5	Diversity	-01466 (sig)	p < 0.001	Large

Analisis Pareto Frontier (*Trade-off*)

Posisi "Sweet Spot"

Pemetaan Trade-off:

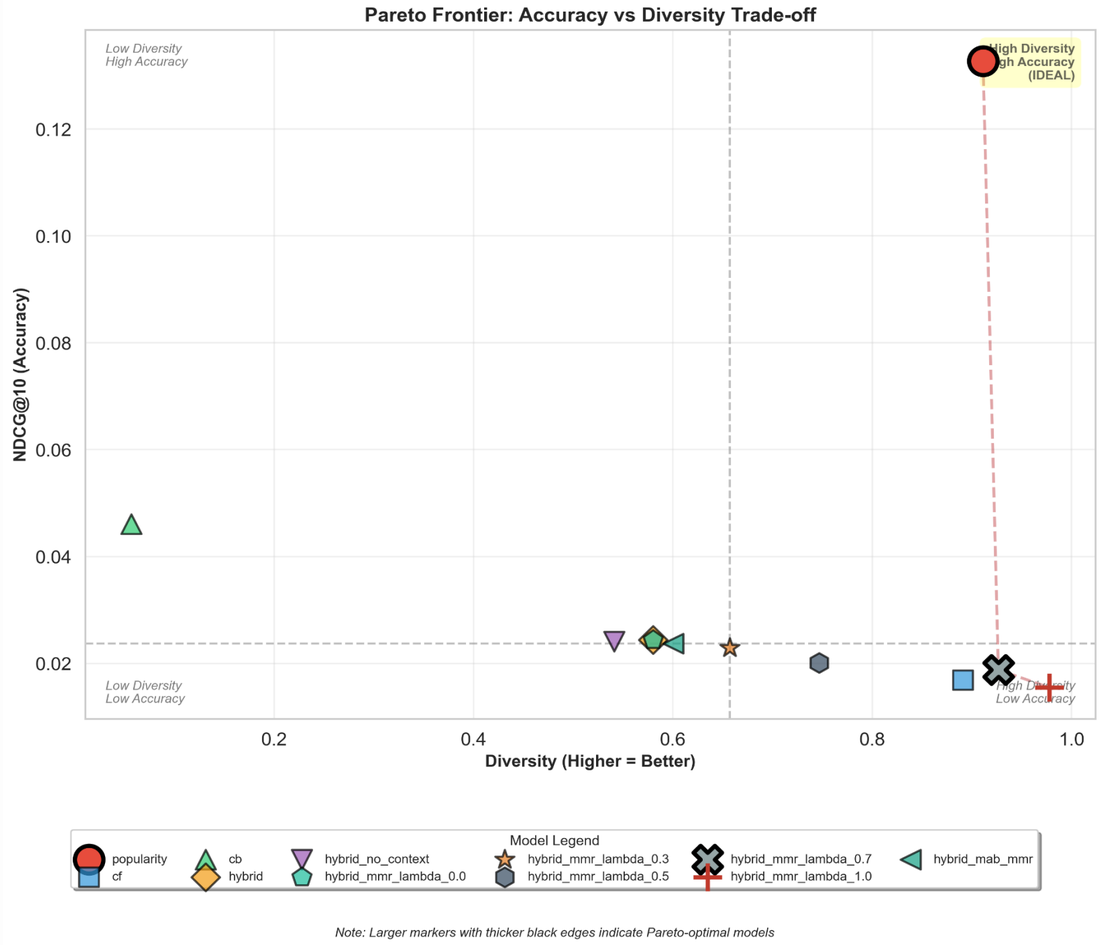
- Sumbu Y (Akurasi/NDCG): Seberapa relevan rekomendasi.
- Sumbu X (Diversitas/ILD): Seberapa bervariasi rekomendasi.

Posisi Model:

- Hybrid Baseline : Akurasi stabil, namun Diversitas terbatas.
- MMR λ=1.0 (+): Diversitas ekstrem (Kanan Bawah), namun mengorbankan Akurasi secara signifikan
- MAB-MMR : Berada di garis Pareto Optimal.

Kesimpulan:

- MAB-MMR mencapai "Sweet Spot": Meningkatkan diversitas (+3.5%) dengan penurunan akurasi yang minimal (tidak signifikan).
- Terbukti lebih efisien dibandingkan menetapkan parameter statis.



Dampak Pemerataan (Long-Tail Coverage)

Peningkatan Eksposur

Sistem berhasil mengangkat destinasi berkualitas tinggi yang sebelumnya "invisible" (terkubur di long-tail).

Total Long-Tail Items Recommended

156 / 224

(69.64% coverage)

Average Boost Long-Tail

+38.4%

vs Baseline

Destinasi	Kategori	Baseline Freq.	MAB-MMR Freq.	Improvement
Curug Pasirwangi	Alam	72	110	+52.78%
Curug Cirengganis	Alam	77	103	+33.77%
Kuliner Si Mbah	Kuliner	81	103	+27.16%
Kampung Budaya	Budaya	65	89	+36.92%
Desa Wisata Ciburial	Desa Wisata	58	82	+41.38%

Dampak Ekonomi & Sosial

Potensi Redistribusi Kunjungan: Peningkatan exposure destinasi long-tail dapat mengurangi overtourism di destinasi populer dan mendorong pemerataan ekonomi pariwisata regional.

HIPOTESIS PENELITIAN

PREMIS

1. Model optimasi dinamis (MAB/RL) mampu menyeimbangkan tujuan yang saling bertentangan secara adaptif (Shi dkk., 2023)
2. Popularity bias memerlukan mitigasi untuk meningkatkan coverage dan fairness (Yalcin & Bilge, 2021; Abdollahpouri dkk., 2020)
3. Integrasi data kontekstual real-time krusial untuk personalisasi adaptif dalam domain pariwisata (Qassimi & Rakrak, 2025)

HIPOTESIS PENELITIAN

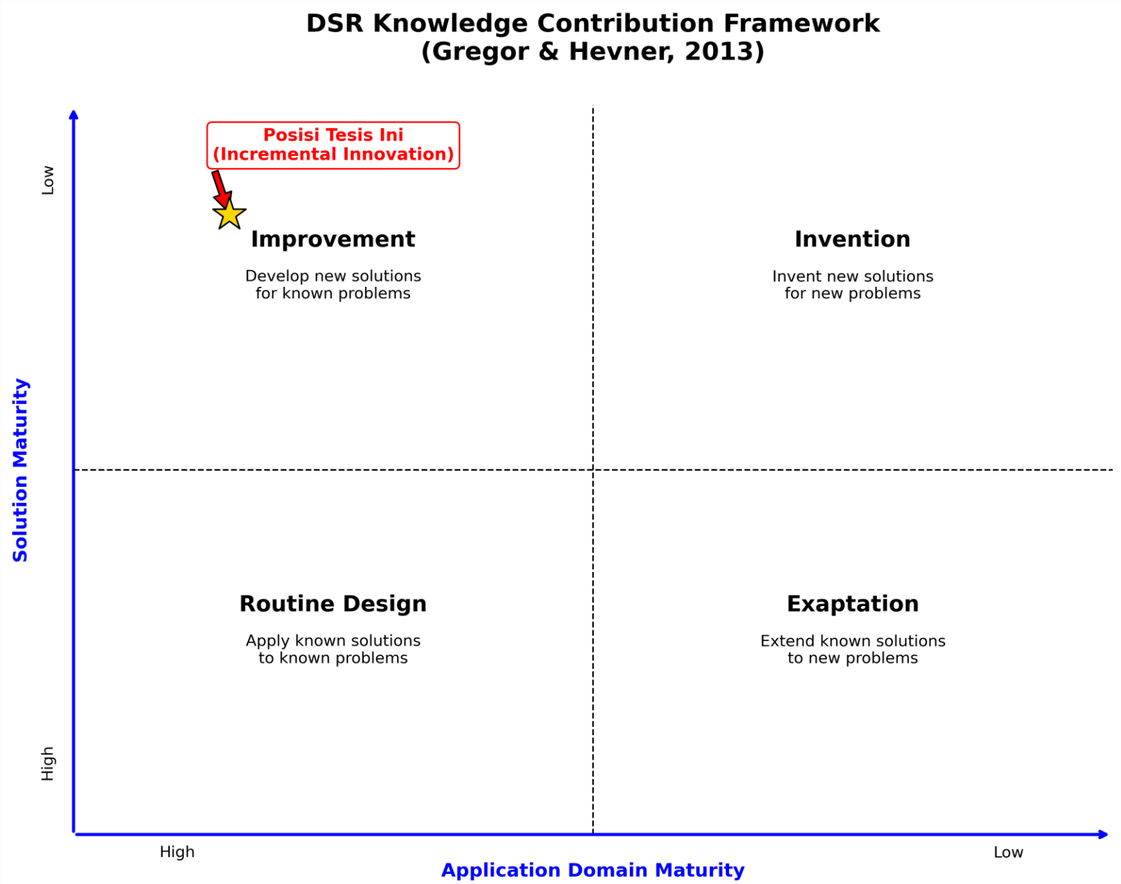
Implementasi Multi-Armed Bandit untuk optimasi parameter dinamis pada Maximal Marginal Relevance yang dikombinasikan dengan pemrosesan kontekstual real-time dapat secara efektif:

1. Mengatasi popularity bias
2. Meningkatkan keberagaman dan cakupan destinasi
3. Mempertahankan akurasi prediktif

dalam sistem rekomendasi pariwisata adaptif

KONTRIBUSI ILMIAH PENELITIAN

Pengembangan mekanisme optimasi parameter adaptif untuk Maximal Marginal Relevance (MMR) menggunakan Multi-Armed Bandit (MAB)



BACKUP SLIDE

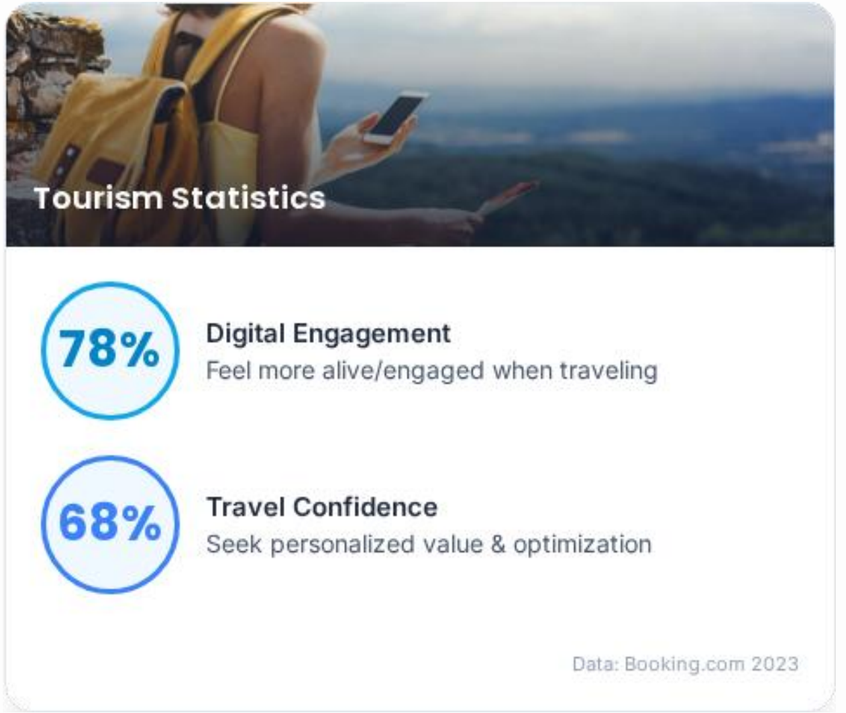
Sistem Rekomendasi dalam Ekosistem Pariwisata Digital

TRANSFORMASI DIGITAL PARIWISATA

Information Overload Problem:
Ledakan informasi digital menyebabkan kesulitan pengambilan keputusan bagi wisatawan.

PERAN STRATEGIS SISTEM REKOMENDASI

- Mengatasi kelebihan informasi (Information Overload)
- Kurasi pengalaman proaktif & personal
- Mengurangi beban kognitif wisatawan
- Mendukung pariwisata berkelanjutan



Paradigma Pariwisata 2.0: Pengalaman Budaya Partisipatif > Konsumsi Pasif

PROCESS FLOW

Information Overload → **Sistem Rekomendasi** → **Meaningful Experience**

BACKUP SLIDE

Tantangan Sistem Rekomendasi Konvensional

DEFINISI & AKAR MASALAH

"Item POPULER direkomendasikan secara TIDAK PROPORSIONAL dibandingkan long-tail."

- **Content-Agnostic:** CF hanya melihat pola interaksi, bukan isi konten.
- **Dominasi Agregat:** Perilaku mayoritas menenggelamkan preferensi niche.
- **Bias Statistik:** Item populer memiliki korelasi data yang jauh lebih tinggi.

SEVERITY (DATA 2021)

- **Item-CF:** < 3% items mendominasi 100% rekomendasi.
- **User-CF:** Dominasi mencapai 99%.

CONTOH: 77 Destinasi Sumedang

10 Destinasi (13%) → **72.4% Rekomendasi**

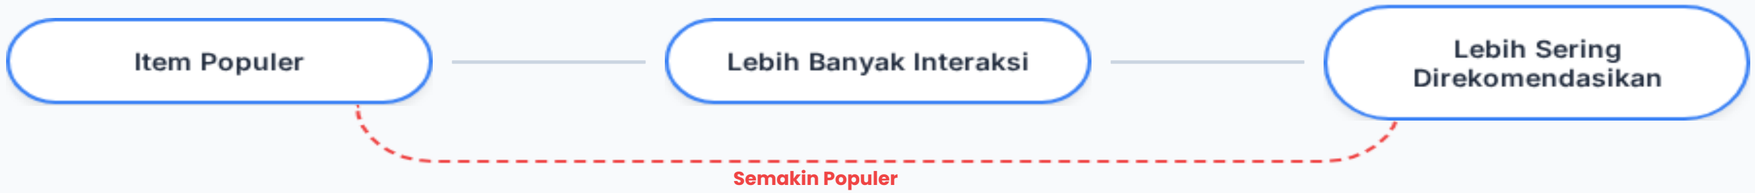
67 Destinasi (87%) → **27.6% Rekomendasi**

Ratio Disparity **1 : 8.7**

DAMPAK PARIWISATA

- **Overtourism:** Kapasitas destinasi populer terlampaui.
- **Algorithmic Invisibility:** Destinasi long-tail terpinggirkan.
- **Ketimpangan Ekonomi:** Distribusi pendapatan daerah tidak merata.
- **Degradasi Autentisitas:** Pengalaman wisata menjadi homogen/pasaran.

EFEK "RICH-GET-RICHER" (Vicious Cycle)



KETERBATASAN PENDEKATAN STATIS:

Parameter MMR (λ) TETAP untuk semua kondisi

Tidak responsif terhadap perubahan KONTEKS

Tidak adaptif terhadap dinamika PARIWISATA

Posisi Penelitian

Penelitian	Thn	Teknik Utama	Context	Adaptive	Diversity	Long-Tail	Gap / Data Gap
Nan dkk.	2022	CF (User-based)	X	X	X	X	Dense; No bias mitigation
Yalcin & Bilge	2021	MMR (λ static)	X	X	✓ (Part)	X	Dense; Static parameter
Yoon & Choi	2023	LSTM + Context	✓	X	X	X	Dense; No diversification
Shi dkk.	2023	RL (DNaIR)	✓	✓	✓	✓ (Part)	Dense; High complexity
Qassimi & Rakrak	2025	MOC-MAB	✓	✓	✓	✓ (Part)	Dense; No tourism focus
Bukhari dkk.	2025	Actor-Critic RL	✓	✓	✓	X	Dense; No diversity
Abdollahpouri dkk.	2021	Bias Mitigation	X	X	✓	✓	Dense; Not context-aware
Solano-Barliza dkk.	2024	Hybrid RS	✓ (Part)	X	X	X	Dense; Conceptual
Penelitian Ini	**2025**	**Hybrid+MAB-MMR + Ctx**	✓	✓	✓	**✓ (Full)**	**Sparse (0.602%)**

IMPLEMENTASI COLLABORATIVE FILTERING (NMF)

ALUR KERJA LIBRARY: NON-NEGATIVE MATRIX FACTORIZATION

(scikit-learn NMF - sklearn.decomposition.NMF)

INPUT DATA:

User-Item Interaction Matrix R (165 users × 224 destinations)

Sparsity: 0.602% (hanya 222 interaksi dari 36,960 kemungkinan)

KEUNGGULAN NMF untuk Pariwisata:

1. Non-negative constraints → interpretable (tidak ada "negative preference")
2. Sparse-aware → efisien untuk data 0.602% sparsity
3. Latent factors capture implicit patterns (mis: "adventure seekers")
4. Regularization mencegah overfitting pada data sparse

HASIL (dari Tesis Bab IV.3.1):

- NDCG@10: 0.0189 (baseline CF)
- Diversity: 0.8911 (sangat tinggi karena popularitas rendah)
- Long-tail Coverage: 58.48%

STEP 1: MATRIX INITIALIZATION

$$R \approx W \times H$$

$R[165 \times 224] \approx W[165 \times 20] \times H[20 \times 224]$

W = User latent factors (20 komponen)
H = Item latent factors (20 komponen)

Init method: 'nndsvda' (NMF double SVD)

STEP 2: ITERATIVE OPTIMIZATION

$$\text{Objective: minimize } ||R - WH||^2 + \alpha||W||^2 + \alpha||H||^2$$

Algorithm: Coordinate Descent (CD)

- Update W while fixing H
- Update H while fixing W
- Repeat until convergence

Hyperparameters (tuned):

- n_components = 20 (latent factors)
- alpha = 0.01 (L2 regularization)
- max_iter = 500
- tol = 1e-4 (convergence threshold)

STEP 3: PREDICTION GENERATION

$$R_{pred} = W \times H$$

For user u, destination d:

$score(u,d) = \Sigma(W[u,k] \times H[k,d])$ for $k=1..20$

Output: Dense matrix [165×224] dengan predicted ratings untuk semua pairs

BACKUP SLIDE

IMPLEMENTASI CONTENT-BASED (TF-IDF + COSINE)

ALUR KERJA LIBRARY: TF-IDF VECTORIZATION + COSINE SIMILARITY

(scikit-learn TfidfVectorizer + cosine_similarity)

INPUT DATA:

Destination metadata (224 destinasi):

• Name, Description, Category, Facilities, Tags

INTERPRETASI TF-IDF WEIGHTS:

Example untuk "Curug Cinulang":

• "waterfall" → TF-IDF = 0.45 (high, distinctive)

• "nature" → TF-IDF = 0.12 (medium, common)

• "the" → TF-IDF = 0.00 (filtered, stop word)

Similarity example:

• Curug Cinulang ↔ Curug Pasirwangi: 0.87 (very similar)

• Curug Cinulang ↔ Museum Prabu Geusan Ulun: 0.02 (very different)

HASIL (dari Tesis Bab IV.3.1):

• NDCG@10: 0.0318 (tertinggi untuk baseline)

• Diversity: 0.0565 (sangat rendah - filter bubble)

• Long-tail Coverage: 33.93% (terendah)

• Precision@10: 0.0076 (tertinggi)

MASALAH FILTER BUBBLE:

CB cenderung rekomendasi destinasi terlalu mirip

→ Perlu diversifikasi (MMR) untuk balance

STEP 1: TEXT PREPROCESSING & TF-IDF

Library: sklearn.feature_extraction.text.TfidfVectorizer

Input: Combined text untuk setiap destinasi

```
"Curug Cinulang | Air Terjun | Hiking Spot
 Natural Beauty Waterfall Photography"
```

TF-IDF Computation:

• Term Frequency (TF): frekuensi kata

• Inverse Document Frequency (IDF):

`IDF(t) = log(N / df(t))`

N = total docs, df(t) = docs with term t

Output: TF-IDF Matrix [224 × vocab_size]
(sparse matrix format untuk efisiensi)

STEP 2: COSINE SIMILARITY COMPUTATION

Library: sklearn.metrics.pairwise.cosine_similarity

Rumus: $\cos(\theta) = (A \cdot B) / (||A|| \times ||B||)$

Dengan:

• A, B = TF-IDF vectors untuk 2 destinasi

• A · B = dot product

• ||A|| = Euclidean norm of A

Computation:

```
similarity_matrix = cosine_similarity(
    tfidf_matrix,   # [224 × vocab]
    tfidf_matrix    # [224 × vocab]
)
# Output: [224 × 224] similarity matrix
```

STEP 3: RECOMMENDATION GENERATION

For user u with interaction history H_u:

1. Ambil destinasi yang disukai user

```
liked_items = [d1, d2, ..., dk]
```

2. Hitung aggregate similarity:

```
score(d) = Σ similarity(d, d_i)
           for d_i in liked_items
```

3. Rank destinasi berdasarkan score

```
recommendations = top_k(scores)
```

BACKUP SLIDE

NOVELTY-NDCG CORRELATION ANALYSIS

PERTANYAAN PENELITIAN:

Apakah peningkatan novelty mengorbankan akurasi?

HASIL KORELASI PEARSON:

Novelty vs NDCG@10

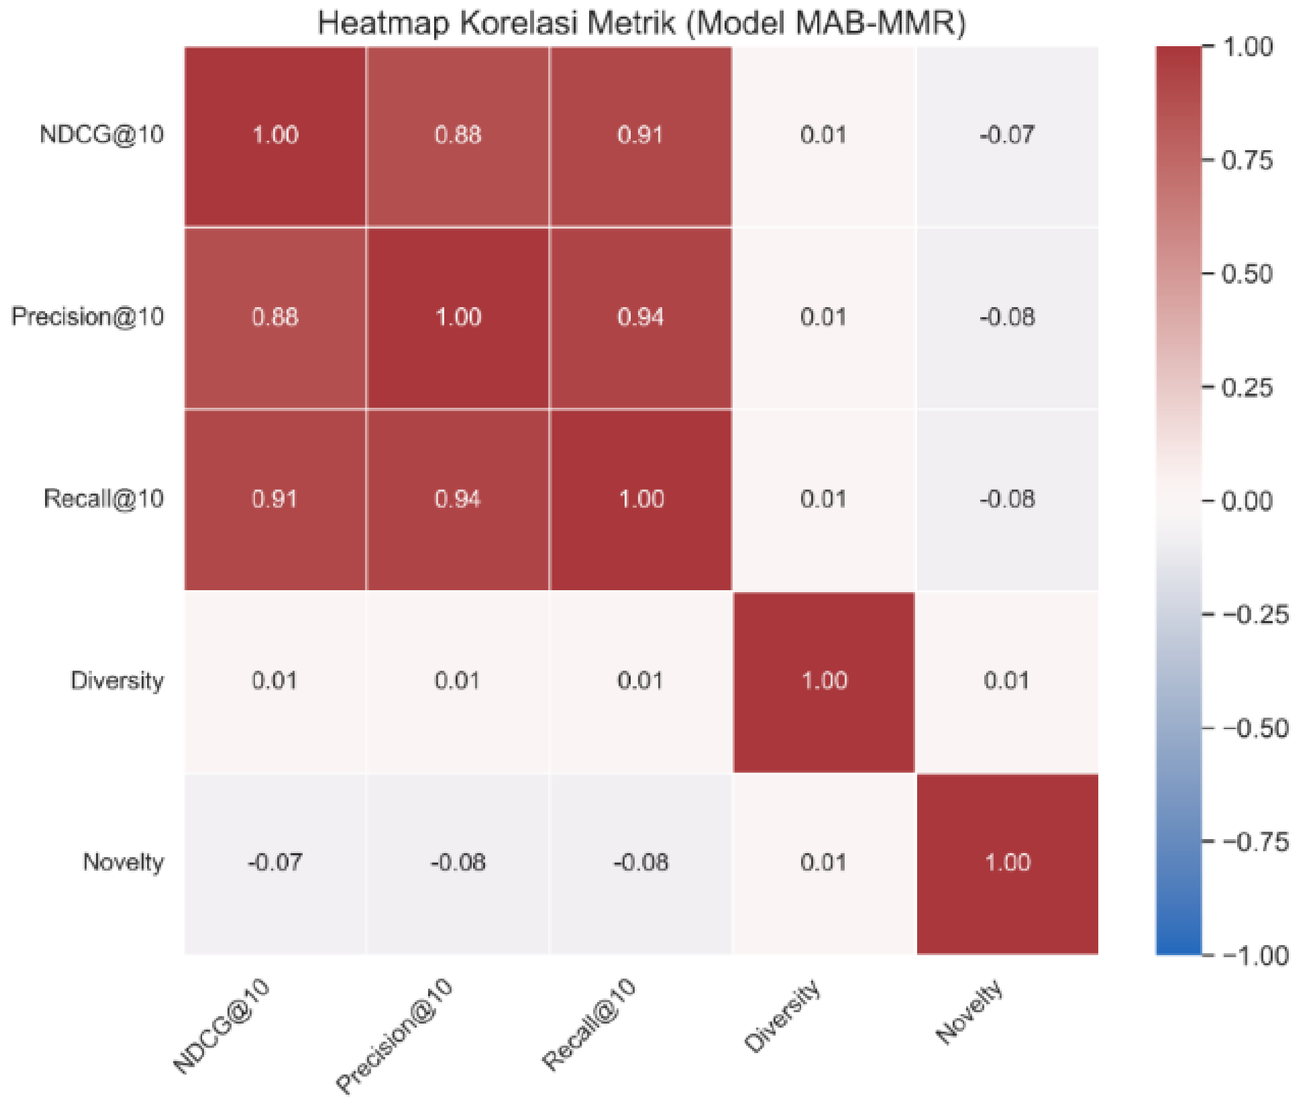
Correlation coefficient: r = -0.0703

Interpretation: WEAK NEGATIVE

p-value: 0.3894 (not significant)

KESIMPULAN :

1. Korelasi Novelty-NDCG sangat lemah (r=-0.07)
2. Artinya: Novelty TIDAK mengorbankan akurasi
3. Korelasi Diversity-Coverage kuat (r=0.81)
4. Korelasi Novelty-Diversity positif (r=0.64)



BACKUP SLIDE

DEMONSTRASI ADAPTABILITAS KONTEKS

Real-time Context-Aware Recommendations

implementasi difokuskan pada pengguna sampel (User ID 1)
yang memiliki preferensi historis pada kategori Wisata Buatan/Rekreasi dan Wisata Budaya.

SKENARIO 1: KONDISI NORMAL (CERAH)

Context:

- Weather: Sunny
- Traffic: Normal
- Crowdedness: Low

MAB Strategy: PERSONALISASI AKURAT

TOP-5 REKOMENDASI:

1. Kampoeng Jarami (Wisata Buatan)
2. Jans Park (Wisata Buatan)
3. Batu Alam (Wisata Buatan)
4. Bendungan Jatigede (Wisata Alam)
5. Taman Pinus (Wisata Alam)

Konsisten dengan preferensi historis user

SKENARIO 2: HUJAN DERAS

Context:

- Weather: Heavy Rain
- Traffic: Medium
- Outdoor accessibility: Limited

MAB Strategy: INTERVENSI KONTEKSTUAL

TOP-5 REKOMENDASI:

1. Wisata Kampoeng Ciherang (Wisata Alam)
2. RM. Cahaya Sari (Wisata Kuliner)
3. Ponyo® Resto (Wisata Kuliner)
4. Saung Alam Flora (Wisata Kuliner)
5. R.M Joglo Sumedang (Wisata Kuliner)

4 dari 5 rekomendasi → Wisata Kuliner indoor

Prioritas kenyamanan > preferensi historis

SKENARIO 3: KEPADATAN PUNCAK

Context:

- Weather: Sunny
- Time: Peak Season / Holiday
- Crowdedness: Very High

MAB Strategy: DIVERSIFIKASI & DECONGESTION

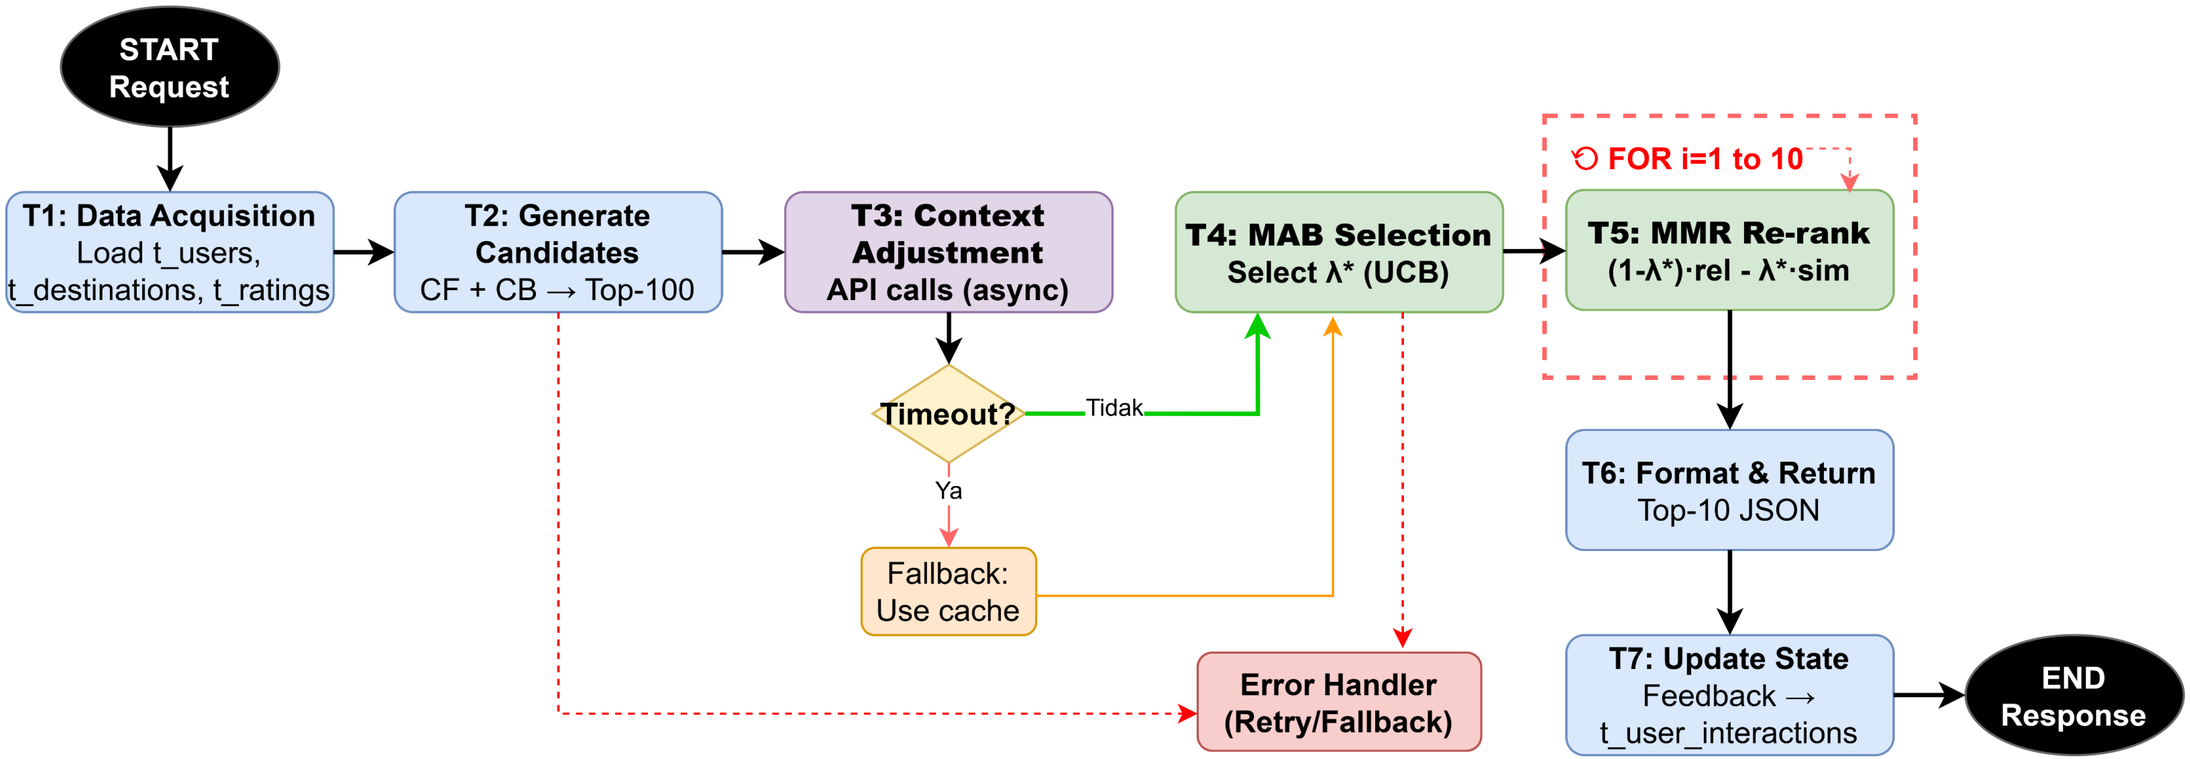
TOP-5 REKOMENDASI:

1. RM Sederhana Hj Erat (Wisata Kuliner)
2. Bendungan Jatigede (Wisata Alam)
3. Taman Pinus Pangjugjugan (Wisata Alam)
4. Batu Alam (Wisata Buatan)
5. Pojok Sawangan Mia (Wisata Kuliner)

Mix kategori: 2 Kuliner + 2 Alam + 1 Buatan

Cegah konsentrasi di satu lokasi

Alur Rekomendasi



BACKUP SLIDE

Alur Pemberian Bobot & Boost/Penalty pada Context

STEP 1: SCORE ORIGINAL (Base Relevance Score)

Collaborative Filtering (CF)

Metode: NMF (n_components=20)

User-Item Matrix:
User 123 × All Items

Matrix Factorization:
U[123] · I[42]ᵀ

Predicted Rating = 3.72

CF = 3.72

Content-Based (CB)

Metode: TF-IDF + Cosine Similarity

Category: Wisata Alam

User Profile (dari history):
[0.12, 0.45, ..., 0.78]

Similarity Score = 0.83
Normalized (×5) = 4.15

CB = 4.15

Hybrid Score (Weighted Sum)

Formula:
Score_Original = (CF × 0.5) + (CB × 0.5)

Calculation:
= (3.72 × 0.5) + (4.15 × 0.5)
= 1.86 + 2.075

= 3.94

Score_Original = 3.94

STEP 2: USER CONTEXT (Informasi Kontekstual)

User Context Input

- Day Type: Weekend
- Weather: Cerah
- Season: Musim Kemarau
- Time of Day: Pagi (09:00)
- Crowd Density: Sedang
- Viral Trend: False
- Special Event: None

Context Rules (Hardcoded)

```
self.context_rules = {
'weekend': {'Wisata Alam': 1.5},
'cerah': {'Wisata Alam': 1.7},
'musim_kemarau': {'Wisata Alam': 1.4},
'pagi': {'Wisata Alam': 1.3},
...
}
```

STEP 3: CONTEXTUAL BOOST CALCULATION (Deviation)

Dimensi Konteks	Kondisi	Boost Factor	Deviation	Formula
1. Tipe Hari	Weekend	**1.5**	**+0.5**	1.5 - 1.0 = +0.5
2. Cuaca	Cerah	**1.7**	**+0.7**	1.7 - 1.0 = +0.7
3. Musim	Kemarau	**1.4**	**+0.4**	1.4 - 1.0 = +0.4
4. Waktu	Pagi	**1.3**	**+0.3**	1.3 - 1.0 = +0.3
5. Kepadatan	Sedang	**1.0**	**0.0**	1.0 - 1.0 = 0.0 (Netral)
6. Viral Trend	False	**-**	**0.0**	Tidak viral → No boost
7. Special Event	None	**-**	**0.0**	Tidak ada event → No boost
TOTAL DEVIATION			**Σ(Deviation) = +1.9**	

Σ(Deviation) = +1.9

STEP 4: FINAL SCORE CALCULATION

Formula Additive Scoring:

Score_Final = Score_Original + Σ(Deviation)

Score_Final = 3.94 + 1.9

Score_Final = 5.84

OUTPUT: RECOMMENDATION RESULT

Recommendation Object (JSON):

```
{
"destination_id": 42,
"name": "Curug Ciparay",
"category": "Wisata Alam",
"score": 5.84,
"boost_amount": 1.9,
"algorithm": "hybrid+context",
"explanation": "CF=1.86 + CB=2.08 + ContextBoost=+1.9",
"context_applied": {
"weekend": 0.5,
"cerah": 0.7,
"musim_kemarau": 0.4,
"pagi": 0.3
}
}
```

Context-Aware Component Details

Dimensi Konteks	Nilai
Weather (Cuaca)	Cerah, Mendung, Hujan
Day Type (Tipe Hari)	Weekend, Weekday, Libur Nasional, Libur Lebaran
Season (Musim)	Musim Kemarau, Musim Hujan
Time of Day	Pagi, Siang, Sore, Malam
Crowd Density	Puncak, Sangat Ramai, Ramai, Sedang, Sepi, Sangat Sepi
Special Events	Festival Kuliner, Festival Budaya, atau None
Viral Trend	True/False

Total Context : 3×4×2×4×6×3×2 = 1,728 Kombinasi
Pembelajaran Bertingkat : 36 base states (Cuaca×Hari×Waktu×Segmen)

Nilai Bobot & Boost/Penalty pada Context

Kondisi	Kategori	Bobot	Boost/Penalty Aditif
Weekend	Wisata Alam	1.5	+0.5
	Wisata Keluarga	1.6	+0.6
	Wisata Buatan/Rekreasi	1.6	+0.6
	Wisata Kuliner	1.4	+0.4
	Wisata Petualangan	1.4	+0.4
	Wisata Budaya & Sejarah	1.1	+0.1
Weekday	Wisata Budaya & Sejarah	1.4	+0.4
	Wisata Religi	1.3	+0.3
	Wisata Kuliner	1.2	+0.2
	Wisata Kesehatan	1.4	+0.4
	Wisata Alam	1.1	+0.1
	Wisata Keluarga	0.8	-0.2 (Penalti)
Libur Nasional	Wisata Buatan/Rekreasi	1.8	+0.8
	Wisata Keluarga	1.8	+0.8
	Wisata Kuliner	1.6	+0.6
	Wisata Alam	1.7	+0.7
	Wisata Petualangan	1.5	+0.5
Libur Lebaran	Wisata Keluarga	2.0	+1.0
	Wisata Buatan/Rekreasi	1.9	+0.9
	Wisata Kuliner	1.7	+0.7
	Wisata Alam	1.5	+0.5

Adomavicius & Tuzhilin (2011), ada tiga paradigma dalam CARS salah satunya adalah rules-based approach.Karena untuk menghitung impact score secara empiris menggunakan formula $\widehat{w}_{uic_j} = f_{c_j} \mid \hat{r}_{uic_j} - \hat{r}_{ui} \mid$,kami memerlukan dataset rating dengan label kontekstual eksplisit